

Projet Data Pipeline

Architecture Médaillon Cloud · Master 2 Data Engineering & IA

CONTEXTE & OBJECTIF

Les équipes choisissent un jeu de données open source (≥ 1 million de lignes) et une ou plusieurs problématiques orientées datamarts. Elles conçoivent, déploient et documentent une pipeline de données complète sur le cloud provider de leur choix (AWS, GCP, Azure, ou autre), du bronze au gold, en justifiant chaque choix technologique et financier avec un comparatif outillé.

DONNÉES OPEN SOURCE — CONSEILS & SOURCES RECOMMANDÉES

Le jeu de données doit comporter **au minimum 1 million de lignes** et être librement accessible. Voici les critères de sélection et des sources fiables :

Critères de sélection d'un bon jeu de données :

- Volume suffisant (1M+ lignes) pour justifier une approche cloud et des optimisations de stockage
- Données temporelles ou partitionnables, pour valider la stratégie de partitionnement
- Plusieurs entités liées (au moins 2–3 tables joinables) pour construire des datamarts riches
- Données avec des enjeux métier identifiables : volumes, anomalies, tendances, prédictions possibles
- Fraîcheur : préférer des jeux mis à jour régulièrement pour mettre en oeuvre l'ingestion incrémentale

Source	URL	Thématiques disponibles
data.gouv.fr	data.gouv.fr	Transports, santé, énergie, emploi, cadastre
NYC Open Data	opendata.cityofnewyork.us	Taxis, 311, crimes, bâtiments, mobilité
Kaggle Datasets	kaggle.com/datasets	E-commerce, finance, santé, sport, tweets
Open Food Facts	world.openfoodfacts.org	Produits alimentaires, nutriscore, additifs
Copernicus / ERA5	cds.climate.copernicus.eu	Météo, climat, température, précipitations
SNCF Open Data	data.sncf.com	Ponctualité, trafic, gares, voyageurs
Open Street Map	download.geofabrik.de	Géospatial, POI, routes, bâtiments
Stack Overflow Survey	survey.stackoverflow.co	Tech, salaires, outils, géographie dev
GitHub Archive	gharchive.org	Activité Git, tendances, contributions

Conseil : prioriser des sources combinables (ex. données SNCF + météo, ou taxis NYC + événements culturels) pour enrichir les problématiques et justifier des jointures silver.

BRONZE

Bronze — Ingestion brute

Ingestion des données sans transformation. Stockage dans l'état brut de la source.

Exigences :

- Choix et justification du format de stockage (Parquet, Delta Lake, Apache Iceberg, ORC, CSV...) selon les critères de performance de lecture, coût de stockage, évolutivité du schéma et compatibilité avec les services cloud choisis.
- Stratégie de partitionnement documentée (par date, région, catégorie...).
- Gestion de l'ingestion incrémentale vs full load, avec justification.
- Politique de rétention et de versionnement des données brutes.

SILVER

Silver — Nettoyage, enrichissement & ML (bonus)

Nettoyage, déduplication, typage, normalisation, jointures. Construction des features pour les datamarts gold.

Exigences :

- Règles de qualité documentées et appliquées (nulls, doublons, valeurs aberrantes).
- Feature engineering orienté métier et traçabilité des transformations.
- Tests de qualité automatisés (dbt tests, Great Expectations, Soda...).

Bonus ML — intégration d'un ou plusieurs modèles :

- Le modèle doit être **intégré dans la pipeline** (pas un notebook standalone) : il doit s'exécuter automatiquement lors du déclenchement de la pipeline silver et ses prédictions doivent être accessibles en couche gold (via API ou dashboard).
- Types de modèles conseillés selon la thématique :

Type de ML	Cas d'usage	Librairies suggérées
Classification	Catégorisation, détection d'anomalies	scikit-learn, XGBoost, LightGBM
Régression / Prévion	Prédiction de volumes, de prix, de trafic	Prophet, statsmodels, scikit-learn
Clustering	Segmentation clients, zones géo, produits	K-Means, DBSCAN, scikit-learn
NLP	Analyse de sentiments, topics, résumés	spaCy, HuggingFace Transformers
Détection d'anomalies	Fraude, pannes, pics de trafic	Isolation Forest, Autoencoders

- Versionnement du modèle (MLflow, W&B, ou service managé du cloud provider).
- Métriques de performance documentées et comparées à une baseline simple.

- Le modèle doit tourner dans l'orchestrateur (tâche dédiée dans le DAG/workflow).
- Les prédictions sont écrites en couche gold et exposées (API ou dashboard).

GOLD

Gold — Exposition, API & Dashboards

Datamarts agrégés et nettoyés, exposés à travers des API REST et des dashboards interactifs. Tous les outils sont libres mais doivent être justifiés opérationnellement et financièrement.

Exigences :

- Au moins une API REST documentée (Swagger/OpenAPI) exposant des endpoints métier.
- Au moins un dashboard interactif (Metabase, Superset, Grafana, Streamlit, Looker...).
- Les datamarts doivent répondre aux problématiques métier identifiées.
- Justification des outils : pourquoi ce dashboard vs les alternatives, coût, maintenabilité.

EXIGENCES TRANSVERSALES OBLIGATOIRES

Exigence	Description	Exemples d'outils
Orchestration	DAG/workflow avec dépendances, retry, scheduling, alertes d'échec	Airflow, Prefect, Dagster, Step Functions, Cloud Composer
Monitoring pipeline	Observabilité : latence, SLA, nb de lignes traitées, taux d'erreur	Datadog, CloudWatch, Prometheus/Grafana, dbt, Great Expectations
Alerting	Alertes configurées et démontrées : seuils, canaux (email, Slack...)	PagerDuty, Opsgenie, SNS, alertes natives orchestrateur
Format de stockage	Choix justifié par couche : performance, coût, compatibilité, schéma	Parquet, Delta Lake, Iceberg, ORC — avec comparatif
Qualité données	Tests de qualité automatisés intégrés dans la pipeline	Great Expectations, Soda, dbt tests, custom checks

ANALYSE FINOPS — EXIGENCES DÉTAILLÉES

L'analyse FinOps est un livrable central, pas une annexe. Elle doit permettre de comprendre le coût réel de construction du projet ET le coût d'exploitation pérenne de la pipeline, avec des justifications comparatives avant chaque choix de service.

1. Tableau de facturation phase développement & recette

Détailler le coût complet pour développer, tester et recetter le projet, incluant toutes les ressources provisionnées (même temporairement) :

- Coût par service et par couche (stockage, compute, orchestration, monitoring, ML...)
- Durée d'utilisation et dimensionnement des ressources durant la phase de dev

- Coûts de transfert de données (ingress / egress entre services)
- Coûts des services managés (DBaaS, SaaS monitoring, outils de visualisation...)
- Total dev/recette avec ventilation par poste

2. Tableau de facturation exploitation quotidienne (run)

Estimer le coût pour faire tourner la pipeline en conditions réelles, au quotidien, sur la base d'un mois d'exploitation :

- Coût par déclenchement de pipeline (ingestion, transformation, exposition)
- Coût de stockage à l'état stable (bronze + silver + gold)
- Coût des API exposées en gold (nombre de requêtes estimées)
- Coût du monitoring et de l'alerting actifs
- Extrapolation sur 1 mois et 1 an, avec hypothèses de volume documentées

3. Comparatifs avant chaque choix de service (obligatoire)

Avant de retenir un service, fournir un tableau comparatif sur au moins 2–3 alternatives. Le comparatif doit couvrir :

Critère	Ce qu'on attend
Coût	Prix à l'usage, coût mensuel estimé pour le volume projet
Performance	Latence, débit, scalabilité au volume cible
Intégration	Compatibilité avec les autres services de la stack
Complexité opérationnelle	Courbe d'apprentissage, maintenance, maturité
Free tier / crédits	Disponibilité d'offres gratuites ou crédits étudiants
Vendor lock-in	Risque de dépendance, portabilité des données
Décision retenue	Synthèse en 2–3 lignes justifiant le choix final

Exemples de choix à comparer : Spark EMR vs Glue vs Databricks, Redshift vs Athena vs BigQuery, Airflow self-hosted vs MWAA vs Cloud Composer, Parquet vs Delta Lake vs Iceberg, Metabase vs Superset vs Grafana.

4. Optimisations FinOps proposées

- Identifier les postes de coût les plus significatifs et proposer des pistes de réduction
- Comparer le coût avec et sans optimisations (spot instances, auto-scaling, compression, lifecycle policies...)
- Utiliser les free tiers et crédits étudiants disponibles (AWS Educate, GCP for Students, Azure Dev Tools)
- Documenter les limites du free tier et le moment où les coûts démarrent

Même avec des données open source, des informations personnelles ou sensibles peuvent être présentes (noms, adresses, coordonnées GPS précises, données de santé, opinions politiques...). Les équipes doivent identifier ces données, évaluer leur sensibilité et mettre en oeuvre les mécanismes de protection appropriés tout au long de la pipeline.

1. Cartographie des données sensibles (Data Mapping)

Avant toute ingestion, réaliser un inventaire des champs potentiellement sensibles et classer leur niveau de sensibilité :

Catégorie RGPD	Exemples de champs	Niveau de risque	Action requise
Données d'identification directe	Nom, prénom, email, numéro de téléphone	Elevé	Pseudonymisation ou suppression
Données d'identification indirecte	Adresse IP, cookies, identifiant appareil	Moyen	Hachage ou tokenisation
Données de localisation	GPS précis, adresse postale, trajet	Moyen	Generalisation spatiale (k-anonymat)
Données sensibles art. 9	Santé, opinion politique, religion, origine ethnique	Tres eleve	Anonymisation forte ou exclusion
Données comportementales	Historique d'achats, navigation, interactions	Faible	Aggrégation ou pseudonymisation légère

2. Techniques de protection à mettre en oeuvre

Choisir et justifier les techniques appropriées selon le niveau de sensibilité et les besoins analytiques. Le choix doit faire l'objet d'un comparatif :

Technique	Principe	Cas d'usage pipeline	Reversible ?
Pseudonymisation	Remplacement par un identifiant non significatif (token)	Bronze → Silver : jointures possibles via table de correspondance securisee	Oui (cle)
Hachage (SHA-256, bcrypt)	Transformation irreversible en empreinte de taille fixe	Emails, IPs : comparaison possible sans stocker la valeur claire	Non
Chiffrement (AES-256, KMS)	Donnee illisible sans cle ; gestion des cle par service cloud (KMS)	Colonnes sensibles chiffrees au repos ; dechiffrement uniquement pour services autorises	Oui (cle)
Anonymisation (suppression / masquage)	Suppression ou remplacement definitif du champ sensible	Gold / dashboards : champs non necessaires a l'analyse supprimes	Non
Generalisation / Floutage	Reduction de la precision (GPS -> commune, age -> tranche)	Localisation : coordonnees GPS ramenees a la granularite ville ou departement	Non

k-Anonymat	Garantir qu'une ligne ne peut distinguer moins de k individus	Silver analytique : tables statistiques ou chaque combinaison représente $\geq k=5$ individus	Non
Differential Privacy	Ajout de bruit statistique garantissant la non-identification	Aggregats gold : statistiques publiées avec garantie mathématique de confidentialité	Non

3. Application par couche médaille

BRONZE

Ingestion brute — données en clair, accès restreint

- Stocker les données brutes dans un bucket/container avec accès strictement limité (IAM, rôles service)
- Activer le chiffrement au repos (SSE-S3, GCS CMEK, Azure SSE) dès l'ingestion
- Logger tous les accès aux données sensibles (audit trail)
- Ne jamais exposer la couche bronze à des utilisateurs finaux ou des services externes

SILVER

Transformation — pseudonymisation et protection active

- Appliquer la pseudonymisation ou le hachage des champs identifiants lors de la transformation bronze → silver
- La table de correspondance pseudonyme/réel est stockée séparément, chiffrée, avec accès ultra-restreint
- Appliquer la généralisation sur les champs de localisation (GPS → commune ou département)
- Documenter chaque transformation RGPD appliquée et sa justification
- Pour le bonus ML : s'assurer que les features d'entraînement ne contiennent aucune donnée identifiante

GOLD

Exposition — anonymisation forte, accès contrôlé

- Les datamarts et API gold ne doivent exposer aucune donnée directement identifiante
- Appliquer le k-anonymat ou la differential privacy sur les agrégats exposés si nécessaire
- Mettre en place un contrôle d'accès aux APIs (authentification, rate limiting, logs d'accès)
- Les dashboards ne doivent pas permettre de ré-identification par croisement de filtres

4. Exigences documentaires RGPD

Les équipes doivent produire, dans le rapport, les éléments suivants :

- Registre de traitement simplifié : finalité, base légale, catégories de données, durée de rétention
- Schéma annoté indiquant où chaque technique de protection est appliquée dans la pipeline

- Politique de rétention : durée de conservation par couche, procédure de suppression (droit à l'effacement)
- Gestion des clés de chiffrement : qui détient les clés, rotation, révocation
- Analyse de risque rapide (AIPD simplifiée) si des données de catégorie art. 9 sont présentes

Outils recommandés : AWS KMS / GCP Cloud KMS / Azure Key Vault pour la gestion des clés, Apache Ranger ou IAM natif pour le contrôle d'accès, Microsoft Presidio ou Google Cloud DLP pour la détection et le masquage automatique de PII dans les données.

LIVRABLES ATTENDUS

Livrable 1 — Rapport technique & métier (document écrit)

- **Thématique & données** : Présentation du jeu de données, source, volumétrie, fraîcheur, justification du choix
- **Problématiques** : 2–3 questions métier orientées datamarts, avec les indicateurs clés attendus (KPIs)
- **Architecture** : Schéma complet Bronze → Silver → Gold avec tous les services nommés et les flux
- **Choix des formats de stockage** : Tableau comparatif par couche, critères évalués, décision retenue
- **Orchestration** : Description du DAG/workflow, dépendances, scheduling, gestion des erreurs
- **Monitoring & alerting** : Métriques surveillées, seuils d'alerte, canaux de notification, captures d'écran
- **Analyse FinOps** : Factures dev/recette + run quotidien + comparatifs avant choix + optimisations
- **Conformité RGPD** : Cartographie des données sensibles, techniques appliquées par couche, registre de traitement, politique de rétention
- **Interprétations métier** : Réponse aux problématiques via dashboards, API, et ML si bonus

Livrable 2 — Vidéo de présentation (10–15 minutes)

- Introduction : thématique, données et problématiques (2 min)
- Walkthrough de l'architecture et des composants (3 min)
- Démo live de la pipeline en fonctionnement (3 min)
- Démonstration des dashboards, API gold et du monitoring (3 min)
- Synthèse FinOps et apprentissages (2 min)

CRITÈRES D'ÉVALUATION

Critère	Pondération	Ce qui est évalué
Architecture & choix techniques	20 %	Pertinence des choix, schéma clair, justifications solides
Qualité du code & orchestration	20 %	Pipeline fonctionnelle, code lisible, DAG bien structuré
Analyse FinOps & comparatifs	20 %	Factures dev + run, comparatifs outillés, optimisations chiffrées

Interprétations métier & gold	15 %	Qualité des datamarts, dashboards, API et réponse aux problématiques
Monitoring, alerting & qualité données	15 %	Observabilité effective, alertes démontrées, tests de qualité
Conformité RGPD	10 %	Cartographie, techniques appliquées, documentation registre + rétention
Bonus ML Silver	+10 %	Modèle intégré pipeline, métriques, prédictions en gold

Rappel : tout service payant doit être anticipé dans l'analyse FinOps. Privilégier les free tiers et crédits cloud étudiants disponibles. La facturation doit rester raisonnable — l'objectif n'est pas de dépenser, mais de démontrer la maîtrise des coûts.